

Fashion-MNIST VAE 中 KL 正则化的作用分析

问题背景与模型

变分自编码器 (Variational Autoencoder, VAE) 是一类概率生成模型。和普通 autoencoder 只学习一个确定的 latent code 不同, VAE 的 encoder 输出近似后验分布

$$q_{\phi}(z | x) = \mathcal{N}(\mu_{\phi}(x), \text{diag}(\sigma_{\phi}^2(x))),$$

并通过 decoder 建模 $p_{\theta}(x | z)$ 。本项目使用标准正态先验 $p(z) = \mathcal{N}(0, I)$, 训练目标为

$$\mathcal{J}_{\beta}(x) = -\mathbb{E}_{q_{\phi}(z|x)}[\log p_{\theta}(x | z)] + \beta D_{KL}(q_{\phi}(z | x) \| p(z)).$$

其中第一项鼓励图像重构, 第二项约束 encoder 学到的 latent distribution 接近标准正态先验。beta 控制这两种目标之间的权衡: 较小的 beta 更重视重构, 较大的 beta 更重视潜空间正则化。

本项目实现了一个用于 28x28 灰度图像的 MLP VAE。模型使用全连接 encoder 和 decoder, 隐藏层维度为 [400, 200], latent dim 为 16。训练和评估均使用 PyTorch 实现, 支持训练、测试集评估、测试图像重构、标准正态先验采样、损失记录和多组实验对比。

实验设置

主要实验使用 Fashion-MNIST。所有正式实验保持模型结构和主要训练设置不变, 只改变 KL 权重 beta。

setting	value
dataset	Fashion-MNIST
model	MLP VAE
hidden dims	[400, 200]
latent dim	16
batch size	128
epochs	20
learning rate	0.001
seed	42
device	CUDA

基础任务比较 beta=1 的标准 VAE 与 beta=0 的 KL 消融模型。开放探索进一步扫描 beta=0, 0.1, 0.5, 1, 2, 4, 研究 KL 权重变化对重构、KL 和先验采样的影响。

基础实验: beta=1 与 beta=0

run	beta	test reconstruction	test KL	test total
fashion_mnist_beta0	0.0	214.24	297.92	214.24
fashion_mnist_beta1	1.0	228.38	12.19	240.57

不同 beta 下的 test_total 不适合直接比较, 因为它包含不同权重的 KL 项。更合理的比较方式是分别观察 reconstruction loss、KL loss 和生成图像质量。

beta=0 的重构损失更低, 重构图像也更清晰。这说明去掉 KL 后, 模型更接近普通 autoencoder, 会优先利用 latent code 记录输入图像细节。但它的 KL 值非常大, 说明近似后验明显偏离标准正态先验。

beta=1 的重构略更平滑, 但 KL 被压到较低范围。从标准正态先验采样时, beta=1 生成的图像中有更多可识别的衣物形状; 而 beta=0 的 prior samples 明显发暗和混乱。这符合 VAE 目标函数的直觉: KL 正则牺牲一部分重构精度, 但让从 $N(0, I)$ 采样更可靠。

开放探索：beta 系数扫描

开放探索问题是：当 KL 权重 **beta** 从小到大变化时，VAE 的重构质量、KL 大小和先验采样质量如何变化？

run	beta	test reconstruction	test KL	test total
fashion_mnist_beta0	0.0	214.24	297.92	214.24
fashion_mnist_beta0_1	0.1	215.64	37.26	219.36
fashion_mnist_beta0_5	0.5	223.13	17.25	231.75
fashion_mnist_beta1	1.0	228.38	12.19	240.57
fashion_mnist_beta2	2.0	233.06	9.31	251.69
fashion_mnist_beta4	4.0	242.32	6.51	268.37

主要趋势很明确：随着 **beta** 增大，test reconstruction loss 上升，而 test KL 下降。这说明更强的 KL 正则会使近似后验更接近标准正态先验，但会降低 latent code 记录输入细节的自由度。




图 1: 不同 β 下的重构结果

从重构图看, $\beta=0$ 和 $\beta=0.1$ 的重构最清晰, 轮廓和对比度更接近输入。 $\beta=0.5$ 开始出现平滑, 但主要类别仍能保留。 $\beta=1.0$ 、 2.0 和 4.0 下图像逐渐更平均化, 纹理和局部细节减少。




图 2: 不同 β 下的先验采样结果

从 prior samples 看, $\beta=0$ 的生成结果最差, 很多样本只有暗色纹理。 $\beta=0.1$ 已经明显改善采样质量, 说明很小的 KL 权重也能显著改善 posterior-prior 匹配。 $\beta=0.5$ 和 $\beta=1.0$ 在本实验中呈现较好的折中: 重构损失没有过高, 采样图像中也有较多可识别衣物。 $\beta=2.0$ 和 $\beta=4.0$ 的采样仍稳定, 但结果更保守和模板化。

结论、局限与资源说明

本项目的核心结论是: KL 正则化控制了重构质量和生成可靠性之间的权衡。去掉 KL 时, 模型能更好地重构输入, 但 latent distribution 不再匹配标准正态先验, 因此 prior sampling 退化。增大 β 会降低 KL、改善潜空间与先验的匹配, 但会提高重构损失并压缩图像细节。对于当前 MLP VAE 和 Fashion-MNIST, $\beta=0.5$ 到 $\beta=1.0$ 是比较合理的折中区间。

局限性包括: 模型是较简单的 MLP VAE, 生成质量有限; 实验只使用 Fashion-MNIST, 训练轮次为 20; 采样质量主要依赖定性观察, 没有引入 FID 等复杂指标。后续可以尝试卷积 VAE、更长训练、latent interpolation, 或比较不同 latent dim 对潜空间性质的影响。

重要资源和使用方式如下: 项目要求 PDF 提供了实验目标和基本公式; Kingma and Welling 的 Auto-Encoding Variational Bayes、Rezende et al. 的 stochastic backpropagation 论文、Higgins et al. 的 beta-VAE 论文用于理解 VAE、重参数化和 β 权重思想; PyTorch 与 torchvision 用于模型实现和 Fashion-MNIST 数据加载; AI 工具用于辅助解释概念、生成学习笔记、整理报告草稿和检查代码, 但实验代码、运行结果和报告结论均基于本仓库实现与实际输出。

参考文献

1. D. P. Kingma and M. Welling. Auto-Encoding Variational Bayes, 2014.

2. D. J. Rezende, S. Mohamed, and D. Wierstra. Stochastic Backpropagation and Approximate Inference in Deep Generative Models, 2014.
3. I. Higgins et al. beta-VAE: Learning Basic Visual Concepts with a Constrained Variational Framework, 2017.